TP Deep Learning: Clasificación de células sanguíneas mediante redes neuronales convolucionales

Diplomatura en Ciencia de datos y análisis avanzado - Módulo 8

Grupo 35: M. Jimena Benito Nacir

Septiembre 2026

Introducción

El objetivo de este trabajo fue desarrollar y comparar redes neuronales convolucionales para clasificar imágenes microscópicas de células sanguíneas: una **CNN propia** y **VGG16**, un modelo preentrenado importado y adaptado mediante transferencia de aprendizaje.

Con autorización del docente, se utilizó **BloodMNIST** en lugar de Intel Image Classification. Este dataset, perteneciente a la colección **MedMNIST** (Acevedo et al., 2020; Yang et al., 2023), contiene 17.092 imágenes en color de 64 × 64 píxeles, distribuidas en ocho categorías: basófilos, eosinófilos, eritroblastos, granulocitos inmaduros, linfocitos, monocitos, neutrófilos y plaquetas.

El problema consiste en asignar cada imagen a una de estas ocho categorías, lo que constituye una clasificación multiclase.

1. Métrica de performance

Para elegir la métrica se consideraron el objetivo del modelo y el costo de sus errores. El objetivo es identificar el tipo celular de cada imagen con fines experimentales, sin que la predicción lleve a ninguna acción clínica; por eso, ningún error es más grave que otro. Además, cada error cuenta a la vez como falso negativo para la clase real y como falso positivo para la clase predicha. En consecuencia, ambos tipos de error se consideraron equivalentes.

Se eligió el **F1 macro** como **métrica principal**. El F1 combina precisión y recall, y el F1 macro promedia las ocho categorías dándoles el mismo peso. Esto es necesario porque las clases están desbalanceadas: los neutrófilos son el 19,5 % del entrenamiento y los linfocitos, el 7,1 %. La exactitud (accuracy) podría ser alta aun si el modelo falla en las clases con menos imágenes.

Como **métricas auxiliares** se usaron la **precisión** y el **recall por clase**. La **matriz de confusión** y las **imágenes mal clasificadas** se usaron para entender qué errores comete el modelo.

En un uso clínico real, los errores no tendrían el mismo peso. Ante la detección de granulocitos inmaduros o eritroblastos, que no suelen encontrarse en sangre periférica de adultos, se revisaría el frotis al microscopio. Un falso positivo solo implicaría una revisión adicional, mientras que un falso negativo podría ocultar una alteración. En ese caso convendría priorizar el recall, ajustando el umbral de

decisión o usando un F2 score. Como este trabajo tiene fines experimentales, se mantuvo el F1 macro.

2. Desarrollo y entrenamiento de los modelos

2.1. Preparación de los datos

Se conservó la división original de **BloodMNIST**: **70 %** de las imágenes para **entrenamiento**, **10 %** para **validación** y **20 %** para **prueba**. Antes de entrenar, se revisó la calidad de los datos: todas las imágenes tenían el tamaño esperado y una etiqueta válida.

Al comparar las imágenes píxel a píxel, se hallaron **17 repetidas**: 8 dentro de entrenamiento y 9 compartidas entre conjuntos. Esto genera fuga de información (**data leakage**), ya que el modelo se evalúa con imágenes que ya vio y sus resultados parecen mejores de lo que son. Además, una misma imagen estaba etiquetada como eosinófilo en entrenamiento y como neutrófilo en prueba, algo equivalente a obtener dos resultados discordantes para una misma muestra.

Se conservó una sola copia de cada imagen repetida, priorizando prueba y luego validación, y se eliminó la imagen con etiquetas contradictorias. En total se excluyeron 18 imágenes. Una verificación posterior confirmó que no quedaban repeticiones.

2.2. CNN propia

Se diseñó una CNN propia con **tres bloques convolucionales**, cada uno seguido de una capa de agrupamiento máximo (**Max Pooling**). Las primeras capas extraen características simples, como bordes, colores y texturas, mientras que las capas más profundas combinan esta información para reconocer patrones relacionados con la forma nuclear y la granulación. Los filtros aumentan de 32 a 128 y las dimensiones espaciales se reducen de 64 × 64 a 8 × 8 píxeles. Posteriormente, **Flatten** transforma los mapas de características en un vector, conectado a una capa densa de 128 neuronas y a una capa **Dropout** del 50 %. La salida contiene ocho neuronas con activación **softmax**, una por categoría celular (**Figura 1**). El modelo posee 1.142.984 parámetros entrenables.

La red se entrenó con el **optimizador Adam**, en lotes de **32 imágenes**, durante un máximo de **30 épocas**. Se detuvo en la época 23 y conservó los pesos de la época 15, con la menor pérdida de validación (**Figura 2**).

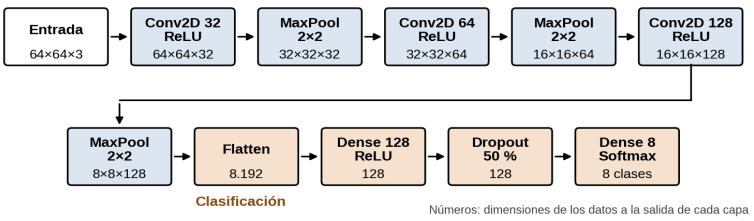


Figura 1. Arquitectura de la CNN propia. Fuente: elaboración propia a partir del resumen del modelo en Keras.

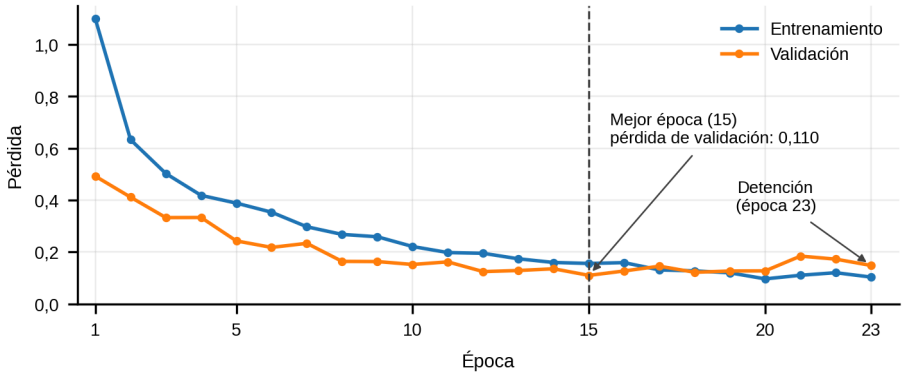


Figura 2. Evolución de la pérdida de la CNN propia por época. La línea punteada marca la época con menor pérdida de validación. Fuente: elaboración propia.

2.3. Transferencia de aprendizaje con VGG16

Como segundo enfoque se importó **VGG16** (Simonyan y Zisserman, 2015) con pesos preentrenados en ImageNet (Deng et al., 2009) y sin su clasificador original. Las imágenes se prepararon con su función **preprocess_input** (TensorFlow, s. f.).

Primero, la base convolucional se mantuvo congelada y se agregó un clasificador con agrupamiento global, una capa densa de 128 neuronas, Dropout y una salida softmax de ocho neuronas. Solo se entrenaron sus 66.696 parámetros; el entrenamiento se detuvo en la época 26 y se conservaron los pesos de la época 18.

Luego se realizó el ajuste fino del último bloque convolucional, con una tasa de aprendizaje reducida (0,00001) y 7.146.120 parámetros entrenables. Esta etapa finalizó en la época 10 y se conservaron los pesos de la época 5.

3. Resultados y análisis

3.1. Comparación del desempeño de los modelos

Los tres modelos se evaluaron sobre el mismo conjunto de prueba (**Tabla 1**).

Modelo	F1 macro	Parámetros totales	Parámetros entrenables	Tiempo de entrenamiento
CNN propia	0,9562	1.142.984	1.142.984	78 s
VGG16 con base congelada	0,8650	14.781.384	66.696	245 s
VGG16 con ajuste fino	0,9220	14.781.384	7.146.120	396 s

Tabla 1. Desempeño y costo computacional de los modelos. El tiempo de VGG16 con ajuste fino suma sus dos etapas de entrenamiento: base congelada (245 s) y ajuste fino (151 s). Fuente: elaboración propia.

La **CNN propia** obtuvo el **mayor F1 macro**, con 13 veces menos parámetros y un tiempo de entrenamiento cinco veces menor que VGG16 con ajuste fino. El ajuste fino mejoró el F1 macro de VGG16, pero no alcanzó a la CNN propia. Esto puede explicarse porque VGG16 fue entrenada originalmente con imágenes de 224 × 224 píxeles: con entradas de 64 × 64, reduce las imágenes a mapas de 2 × 2 y pierde

información espacial. Además, lo que VGG16 aprendió en ImageNet se transfiere solo en parte a imágenes microscópicas.

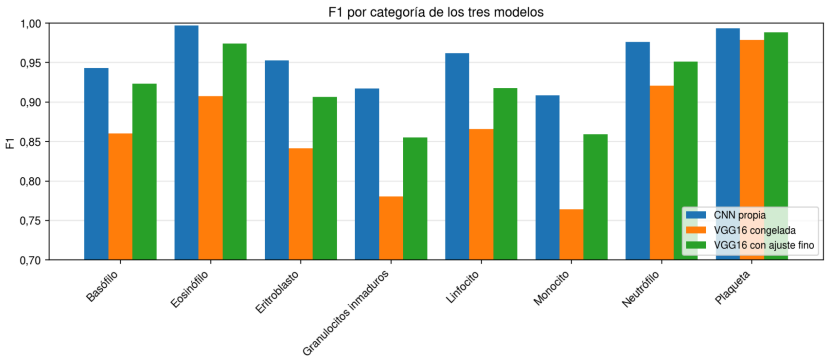


Figura 3. F1 por categoría de los tres modelos. Fuente: elaboración propia.

La ventaja de la CNN propia se mantuvo en las ocho categorías (**Figura 3**). Los tres modelos reconocieron mejor las plaquetas y presentaron más dificultades con los monocitos y los granulocitos inmaduros. El ajuste fino mejoró a VGG16 en todas las categorías, especialmente en las más difíciles.

3.2. Matriz de confusión del modelo seleccionado

La **CNN propia** clasificó correctamente 3.287 de 3.420 imágenes (**Figura 4**). Los eosinófilos y las plaquetas tuvieron la menor proporción de errores. La mayoría de las confusiones involucró a los granulocitos inmaduros: 22 monocitos, 17 basófilos, 12 neutrófilos y 10 eritroblastos fueron clasificados erróneamente como granulocitos inmaduros, y a su vez 14 granulocitos inmaduros fueron clasificados como monocitos y 13 como neutrófilos. Estas confusiones podrían deberse a rasgos compartidos, como el tamaño celular, la forma del núcleo y la granulación.

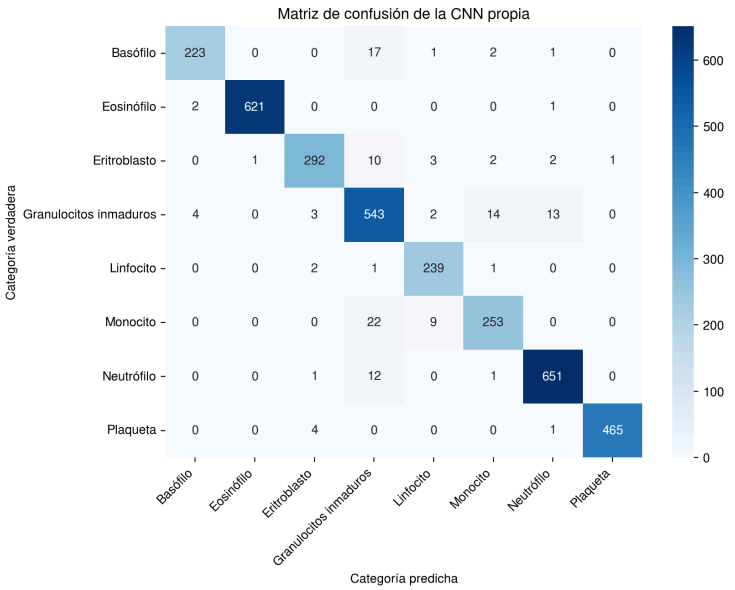


Figura 4. Matriz de confusión de la CNN propia sobre el conjunto de prueba (filas: categoría verdadera; columnas: categoría predicha). Fuente: elaboración propia.

3.3. Análisis de imágenes mal clasificadas

En siete de los nueve errores seleccionados intervinieron los granulocitos inmaduros (**Figura 5**). Algunos monocitos presentan núcleos plegados o indentados, parecidos a los de ciertos granulocitos inmaduros. En dos eritroblastos, el recorte incluye otra célula o material de tinción, que pudo influir en la predicción. Las probabilidades de los errores fueron de entre 48,93 % y 99,46 %, por lo que una probabilidad alta no garantiza una clasificación correcta.

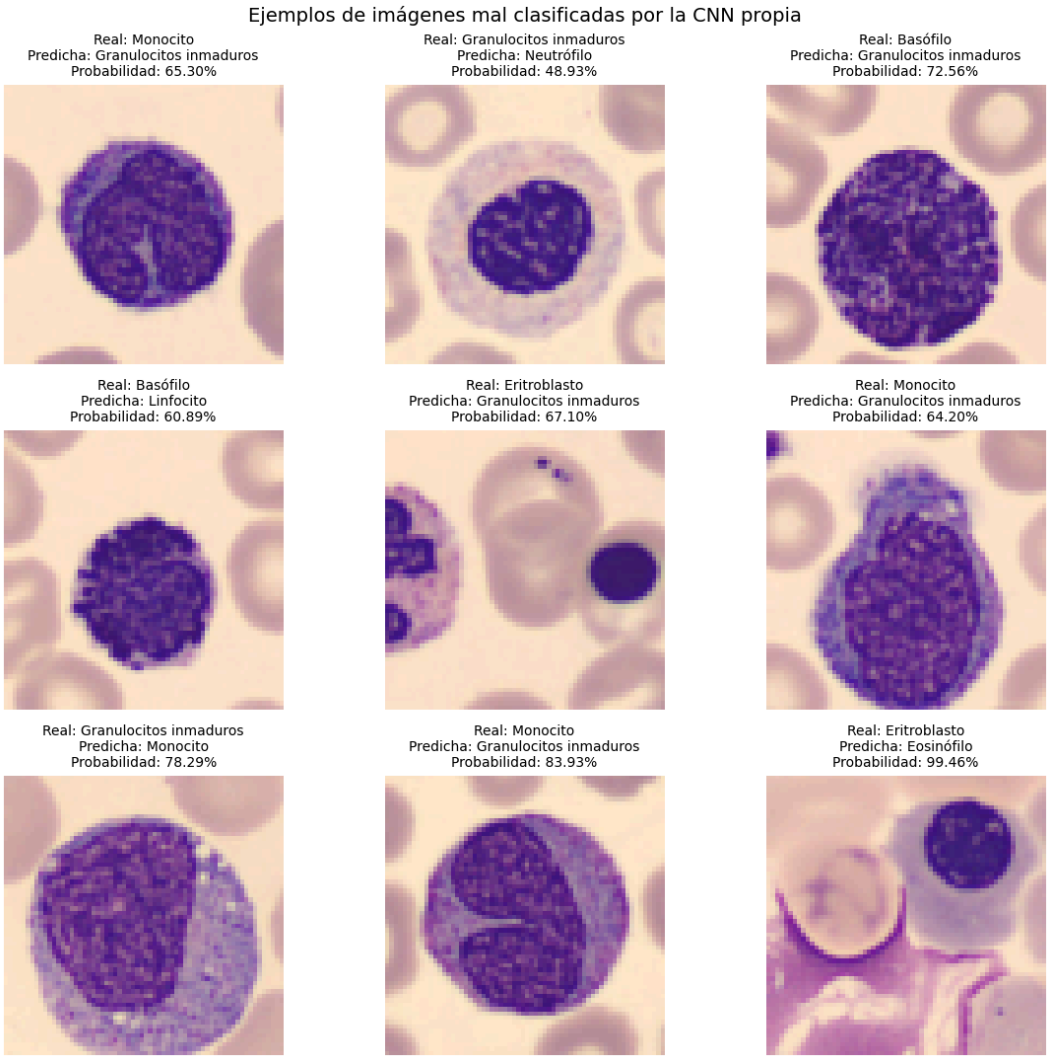


Figura 5. Ejemplos de imágenes mal clasificadas por la CNN propia. Cada imagen indica la categoría verdadera, la categoría predicha y la probabilidad asignada a esa predicción. Fuente: elaboración propia con imágenes de BloodMNIST (Acevedo et al., 2020; Yang et al., 2023).

3.4. Conclusión

Se eligió la **CNN propia** como modelo final, porque obtuvo el **mayor F1 macro** (0,9562) con el **menor costo computacional**. Un modelo más grande y preentrenado no siempre es la mejor opción: una red más simple, entrenada con las imágenes del problema, fue más precisa y eficiente.

Los errores del modelo coinciden con las dificultades de la observación al microscopio: diferenciar monocitos de granulocitos inmaduros requiere apreciar detalles de la cromatina y la granulación que se pierden a 64 × 64 píxeles. Por eso, el modelo no reemplaza la revisión profesional.

Como mejoras, se propone usar **data augmentation** e imágenes de mayor resolución. Antes de cualquier uso clínico, sería necesario validarlo con imágenes de otros laboratorios y con criterios morfológicos especializados.

4. Bibliografía

Acevedo, A., Merino, A., Alférez, S., Molina, Á., Boldú, L. y Rodellar, J. (2020). A dataset of microscopic peripheral blood cell images for development of automatic recognition systems. *Data in Brief*, *30*, 105474. https://doi.org/10.1016/j.dib.2020.105474

Deng, J., Dong, W., Socher, R., Li, L.-J., Li, K. y Fei-Fei, L. (2009). ImageNet: A large-scale hierarchical image database. En *2009 IEEE Conference on Computer Vision and Pattern Recognition* (pp. 248–255). IEEE. https://doi.org/10.1109/CVPR.2009.5206848

Simonyan, K. y Zisserman, A. (2015). *Very deep convolutional networks for large-scale image recognition* [Ponencia]. International Conference on Learning Representations, San Diego, Estados Unidos. https://arxiv.org/abs/1409.1556

TensorFlow. (s. f.). *tf.keras.applications.VGG16*. https://www.tensorflow.org/api_docs/python/tf/keras/applications/VGG16

Yang, J., Shi, R., Wei, D., Liu, Z., Zhao, L., Ke, B., Pfister, H. y Ni, B. (2023). MedMNIST v2: A large-scale lightweight benchmark for 2D and 3D biomedical image classification. *Scientific Data*, *10*, 41. https://doi.org/10.1038/s41597-022-01721-8